



Seminararbeit zum Thema:

**Fehlertoleranz und Robustheit eines komplexen
Smart-Grid-Netzwerks**

Fakultät für Mathematik und Informatik
FernUniversität in Hagen

eingereicht bei:
apl. Prof. Dr. Zhong Li

eingereicht von:
Aymane Bouchaara, 3529908
Carina Vetter, 2153378
Bianca Schwob, 7659954

Abgabedatum: 04.01.2026

Inhaltsverzeichnis

1 Einleitung

Die modernen Stromnetze werden durch die stärkere Digitalisierung und die Menge an dezentralen Energiequellen immer komplexer. Sie entwickeln sich zu sogenannten Smart Grids. Um einen effizienten und stabilen Netzbetrieb zu garantieren, kombinieren sie dabei die physische Strominfrastruktur mit Informations- und Kommunikationstechnologien (Gungor et al., 2013). Denn schwankende Erzeugung und dynamische Lastsituationen können das Netz, z.B. durch die stetig wachsende Anzahl an einspeisenden PVC-Anlagen, überlasten. Gleichzeitig erhöht diese enge Vernetzung jedoch auch die Verwundbarkeit des Systems. Ausfälle einzelner Komponenten, Überlastsituationen, oder gezielte Angriffe können sich aufgrund durch wechselseitige Abhängigkeiten schnell ausbreiten und damit kritische Stromversorgungsstörungen verursachen. Tatsächlich zeigen frühere großflächige Netzausfälle bereits deutliche Beispiele solcher Gefahren (Buldyrev et al. 2010). Vor diesem Hintergrund rückt das Konzept der Resilienz verstärkt in den Fokus. Resilienz definiert, wie gut ein System unter Belastung weiterarbeitet oder sich danach wieder erholt. Damit gilt es als entscheidender Maßstab für künftige Energiesysteme (Holling, 1973). Zur Erforschung der Strukturmerkmale von Smart Grids bei Störungen bietet die Theorie komplexer Netze eine nützliche Grundlage. Sie ermöglicht es, Energienetze als graphbasierte Modelle darzustellen. Es können kritische Knoten und Verbindungen identifiziert werden und die Robustheit und Resilienz können gegenüber zufälligen Ausfällen und gezielten Angriffen quantitativ bewertet werden (Albert, Jeong Barabási, 2000). Unterschiedliche Netzwerktopologien, etwa zufällige Netzwerke nach Erdős und Rényi, Small-World-Strukturen nach Watts und Strogatz oder skalenfreie Netzwerke nach Barabási und Albert zeigen charakteristische Resilienz- und Verwundbarkeitsmuster auf. Diese Typen unterscheiden sich klar im Grad ihrer Widerstandskraft sowie Schwachstellenverteilung, was direkt für den Entwurf echter Energieversorgungsnetze genutzt werden kann (Newman, 2018). Vor diesem Hintergrund vielfältiger Analysemöglichkeiten entsteht daher folgende Fragestellungen: Welche konkreten Merkmale beeinflussen tatsächlich die Stabilität dieser Netze? Wie lässt sich diese durch gezielte Maßnahmen steigern? Zweck dieser Studie ist die systematische Untersuchung der Resilienz von Smart Grids anhand netzwerkbasierter Verfahren und algorithmischer Auswertungen. Dafür werden Stromnetze als komplexe Netze dargestellt, unterschiedliche Störverläufe nachgebildet sowie Maßzahlen für Widerstandsfähigkeit ermittelt. Mithilfe dieser Ergebnisse lassen sich dann konkrete Gestaltungselemente erkennen, auch Hinweise auf mögliche Verbesserungen bei der Stabilität sollten sich erkennen lassen. Damit soll ein Teil zum besseren Erfassen der Netzrobustheit geleistet werden und gleichzeitig Impulse für den Aufbau flexibler, belastbarer und langfristig tragfähiger Systeme geliefert werden.

2 Grundlagen

2.1 Smart Grids: physische Ebene sowie Informations- und Kommunikationstechnik

Moderne Energiesysteme befinden sich in einem tiefgreifenden Wandel, der durch den verstärkten Einsatz erneuerbarer Energien, dezentrale Erzeugungsstrukturen und einer zunehmenden Volatilität im Netzbetrieb gekennzeichnet ist. Um diesen Herausforderungen erfolgreich begegnen zu können, entwickeln sich traditionelle Stromnetze zu sogenannten Smart Grids weiter. Diese kombinieren reale Infrastruktur mit digitalen Technologien für Überwachung, Steuerung und Effizienz (Gungor et al., 2013). Die physische Ebene besteht dabei aus Erzeugungsanlagen, Umspannwerken, Leitungen, Transformatoren und Lasten, die gemeinsam die zusammen das Grundgerüst der Netzstruktur bilden. Ergänzt wird sie durch eine digitale Ebene, welche aus Messsystemen, Kommunikationsnetzen, Regelalgorithmen und Datenplattformen besteht. Letztere fördert Austauschprozesse zwischen Anbietern und Nutzern (Fang et al., 2012). Eine Schlüsselkomponente dieser digitalen Infrastruktur ist die sog. Advanced Metering Infrastructure (AMI), welche mithilfe intelligenter Zähler den Energieverbrauch in Echtzeit erfasst und damit zur Netzzustandsbewertung beiträgt. Weitere wichtige Komponenten sind SCADA-Systeme, Sensorik zur Überwachung von Spannungen und Frequenzen sowie Kommunikationsprotokolle wie IEC 61850, die den Datenaustausch im Netz standardisieren (NIST, 2014). Mit diesen Bausteinen lässt sich das Netz genauer beobachten, Lasten effizienter steuern, Fehler rascher identifizieren. Allerdings führt diese Vernetzung zwangsläufig dazu, dass digitale und reale Systeme enger verflochten sind, was wiederum neue Schwachstellen begünstigt. Angriffe auf Netzwerke oder Fehler in Programmen können direkte Auswirkungen auf technische Systeme haben und Störungen entstehen, die sich schrittweise verstärken lassen (Buldyrev et al., 2010). Bei der Untersuchung der Widerstandsfähigkeit ergibt sich daher ein zentrales Problem: physikalische wie elektronische Vernetzungen müssen einzeln erfasst werden; nur zusammen erklären sie das Gesamtsystemverhalten.

2.2 Komplexe Netzwerke: Knoten, Kanten, typische Topologien

Komplexe Netze zeigen vereinfacht, wie echte Systeme funktionieren – dabei werden Bausteine mit ihren Verbindungen durch Grafiken dargestellt. Eine solche Struktur enthält Punkte, sogenannte Knoten, verbunden über Linien, genannt Kanten, welche Austauschprozesse abbilden (Newman, 2018). In intelligenten

Stromnetzen stehen diese Knoten meist für technische Komponenten wie Umspannwerke, Transformatorstationen, Steuerzentralen oder lokale Energiequellen. Die verbindenden Elemente hingegen symbolisieren entweder reale Leitungen. Entscheidend dafür, wie gut das Gesamtsystem Störungen aushält, ist nicht nur die Menge der beteiligten Einheiten, sondern auch deren Vernetzungsart.

2.2.1 Knoten

Ein Knoten bildet die Basis eines Netzwerks. Abhängig vom Kontext handelt es sich um ein Gerät, eine Stelle in einer Struktur oder einen gedanklichen Punkt. Die Zahl der Linien, die von ihm wegführen, heißt Grad des Knotens. Wichtig ist dieser Wert, weil er zeigt, wie bedeutend ein Knoten ist. Besonders viele Verbindungen haben oft wichtige Knoten im Stromnetz, das macht sie empfindlich.

2.2.2 Kanten

Kanten zeigen, wie Knoten miteinander verbunden sind. In technischen Systemen, etwa bei Smart Grids, dienen sie dem Transport von Energie oder Daten. Zu ihren zentralen Merkmalen gehören sogenannte gewichtete Kanten. Dieses Gewicht steht im Stromnetz beispielsweise für Parameter wie Leitungsbelastbarkeit oder Widerstand. Darüber hinaus spielt die Richtung (gerichtet/ungerichtet) eine Rolle. Bei rein struktureller Betrachtung gelten Stromnetze als ungerichtet; sobald Leistungsflüsse ins Gewicht fallen, werden sie dagegen als gerichtet angesehen. Knoten mit Kanten prägen die Struktur eines Netzwerks, was sein Verhalten bei Belastung beeinflusst, ebenso wie die Reaktion auf Störungen.

2.2.3 Zentralitätsmaße

Zentralitätsmaße quantifizieren die Bedeutung eines Knotens. Beispiele dafür sind die folgenden drei Maße. Betweenness Centrality: Sie misst, wie häufig ein Knoten auf den kürzesten Pfaden zwischen anderen Knoten liegt. Das ist wichtig für die Flusskontrolle. Sie wird durch folgenden Ausdruck gemessen:

$$g(v) = \sum_{s \neq v \neq t} \frac{\sigma_{st}(v)}{\sigma_{st}}$$

st ist dabei die Gesamtzahl der kürzesten Wege vom Knoten s zum Knoten t und σ_{st} die Anzahl, wie oft ein Knoten auf diesen liegt. Daraus folgt folgender

$$C(x) = \frac{N-1}{\sum_y d(y,x)}$$

N ist in der Abbildung dabei die Anzahl der Knoten im Graphen. Die Normalisierung der Closeness (Nähe-Zentralität) erleichtert den Vergleich von Knoten in Graphen unterschiedlicher Größe. Bei sehr großen Graphen wird das „minus eins“ in der Normalisierung vernachlässigbar und daher häufig weggelassen. Degree Centrality: Die Degree Centrality bezeichnet die Bedeutung eines Knotens in einem Netzwerk anhand der Anzahl seiner direkten Verbindungen. Sie entspricht dem Knotengrad und misst, wie viele Kanten von einem Knoten ausgehen. Ein Knoten mit hoher Degree Centrality hat viele Nachbarn und spielt daher eine wichtige Rolle für die lokale Konnektivität des Netzwerks. In ungerichteten Netzwerken entspricht die Degree Centrality der Anzahl aller benachbarten Knoten. (Freeman, 1979).

2.2.4 Topologien

Komplexe Netzwerke können auf unterschiedliche Weise strukturiert sein. Drei grundlegende Modelle haben sich bisher zur Beschreibung und Simulation realer Systeme etabliert: Erdős–Rényi-Netzwerke, Watts–Strogatz-Small-World-Netzwerke und Barabási–Albert-skalenfreie Netzwerke. Diese Topologien unterscheiden sich hinsichtlich Verbindungsstruktur, Gradverteilung, Clusterkoeffizient und typischer Pfadlängen und damit auch hinsichtlich ihrer Resilienz. Das Erdős–Rényi-Netzwerk, ER-Modell, (Erdős Rényi, 1959) erzeugt ein Netzwerk, indem zwischen allen möglichen Knotenpaaren jeweils mit einer festen Wahrscheinlichkeit p eine Kante gezogen wird. Diese zufällige Verbindungsstrategie hat mehrere Konsequenzen: Die Gradverteilung ist binomial- bzw. in großen Netzen näherungsweise Poisson-verteilt und die meisten Knoten haben ähnliche Gradwerte. Der Clusterkoeffizient ist vergleichsweise gering, da nur wenige Dreiecksbeziehungen entstehen. Die Pfadlänge ist typischerweise klein (logarithmisch mit Netzwerkgröße). Die Resilienz ist moderat robust gegenüber zufälligen Ausfällen, aber vulnerabel gegenüber gezielten Angriffen, da keine systematische Struktur existiert, die kritische Knoten schützt. ER-Netzwerke bilden eine wichtige Baseline, aber reale Stromnetze weisen häufig strukturierte Muster auf, die durch dieses Modell nicht vollständig beschrieben werden können. Das Small-World-Netzwerk-Modell (Watts Strogatz, 1998) kombiniert Merkmale regulärer und zufälliger Netzwerke. Die Konstruktion erfolgt durch Ausgang eines regulären Rings, in dem Knoten mit ihren nächsten Nachbarn verbunden sind, und anschließend eine zufällige „Umverteilung“ einzelner Kanten passiert. Charakteristische Eigenschaften: Eine hohe lokale Clusterbildung - also eine lokale Redundanz - wird geschaffen. Diese Knoten haben viele gemeinsame Nachbarn. Die durchschnittliche Pfadlänge ist eher kurz. Dadurch existiert eine effiziente Erreichbarkeit im gesamten Netzwerk. Die Resilienz ist durch hohe lokale Clusterung vergleichsweise hoch und damit das Netzwerk widerstandsfähiger gegenüber Ausfällen. Jedoch ist es

anfällig für Störungen, wenn die wenigen „Shortcut“-Kanten ausfallen, die die Pfadlänge stark reduzieren. Small-World-Strukturen treten in vielen Energie- und Informationsnetzen auf, da sie Effizienz mit lokaler Stabilität verbinden. Von besonderer Bedeutung sind skalenfreie Netzwerke nach Barabási und Albert, deren Knotengradverteilung einem Potenzgesetz folgt. Das BA-Modell (Albert, Jeong Barabási, 2000) basiert auf „präferentieller Anbindung“ von Knoten. Es werden nacheinander Knoten hinzugefügt und sie werden bevorzugt mit bereits gut vernetzten Knoten verbunden („the rich get richer“). Dadurch entstehen sog. Hubs. Eigenschaften: Die Gradverteilung folgt einem Potenzgesetz (scale-free). Dadurch entstehen wenige Hubs mit vielen Knoten mit geringem Grad. Der Clusterkoeffizient ist vergleichsweise gering, kann aber je nach Erweiterung variieren. Die Pfadlängen ist sehr kurz, da Hubs viele Wege verbinden (ultra-small world). Die Resilienz ist hoch, da das Netzwerk sehr robust gegen zufällige Ausfälle ist (da diese meist kleine Knoten betreffen). Es ist aber stark anfällig gegenüber gezielten Angriffen auf Hubs, da das Netzwerk leicht fragmentieren kann. Viele reale Infrastrukturnetze, einschließlich Kommunikationssysteme, Internet-Backbones und Teile moderner Stromnetze, zeigen skalenfreie Eigenschaften. Daher ist das BA-Modell besonders relevant für Analysen der Verwundbarkeit kritischer Infrastrukturen.

2.3 Zentrale Metriken

Im Folgenden werden die Metriken, welche zentral für die Analyse von Netzwerkstrukturen sind, erläutert und dargelegt, welche Relevanz diese jeweils für Smart-Grids haben.

2.3.1 Gradverteilung $P(k)$

Die Gradverteilung $P(k)$ ist die Wahrscheinlichkeit, dass ein Knoten eines Netzwerkes Grad k hat und liegt zwischen 0 und 1. Die Gradverteilung eines Netzwerkes zeigt die Beschaffenheit deren Gesamtstruktur auf und kann somit der Feststellung damit einhergehender, typischer Eigenschaften dienen. Für Smart Grids ist die Feststellung solcher typischen Eigenschaften insofern relevant, als dass hierdurch kritische Hubs identifiziert werden können, wie z.B. große Umspannwerke mit einer besonders hohen Anzahl an Leitungsverbindungen. Die Gradverteilung von Stromnetzwerken weist die grundsätzlichen Bedingungen der Skalenfreiheit auf: Zum Einen ist durch stetigen Ausbau des Stromnetzes das Wachstum als Voraussetzung gegeben. Ebenso werden die Kraftwerke vorzugsweise über stärker vernetzte Umspannwerke angebunden, anstatt perifer dezentral geleitet zu werden. Somit entsteht die typische Gradverteilung, die dem Po-

tenzgesetz entspricht $P(k) \sim k^{-\gamma}$. Bei dieser Verteilung wird die Wahrscheinlichkeit $P(k)$ bei wachsendem k immer kleiner. Im Falle von Stromnetzwerken, bspw. in der westlichen USA, liegt γ ca. bei 4 und somit an der Grenze der Eigenschaften der Skalenfreiheit : die Anzahl großer Hubs ist vergleichsweise gering und stößt mit einer Gesamtzahl von einigen tausend Kraftwerke relativ schnell an eine natürliche Obergrenze.

2.3.2 Clustering-Koeffizient C

Der Clustering-Koeffizient C beschreibt, ob zwei Nachbarn eines Knotens ebenfalls füreinander Nachbarn sind und damit die Ausprägung der Transitivität des Netzwerkes :

$$C = \frac{\text{Anzahl geschlossener Dreiecke}}{\text{Anzahl möglicher Dreiecke}}$$

Bei einer sehr großen Anzahl an Knoten N eines Netzwerks wird der Clustering-Koeffizient sehr klein. Diese Ausprägung eines Extremfalls ist bei Stromnetzen aufgrund der begrenzten Knotenanzahl jedoch nicht gegeben. Relevant wird der Clustering-Koeffizient dann, wenn einzelne Knoten und Verbindungen ausfallen. Der Koeffizient gibt an, wie groß die Redundanz im Netzwerk ist. Ist ein hoher Clustering-Koeffizient gegeben, so stehen im Netzwerk mehrere alternative Pfade bei Ausfällen zur Verfügung, was für Robustheit des Netzwerks gegen lokale Ausfälle sorgt.

2.3.3 Mittlere Pfadlänge ℓ , Durchmesser und Effizienz

Die mittlere Pfadlänge beschreibt die mittlere kürzeste Entfernung zwischen Knoten. Dieser Kennwert ist relevant, um die Ausbreitung von Lastfluss oder Störungen zu beschreiben und um die Wiederherstellungszeit einzuschätzen . Die mittlere Pfadlänge lässt sich wie folgt berechnen:

$$\ell = \frac{1}{N(N-1)} \sum_{i,j} d_{ij}$$

Wobei d_{ij} die durchschnittliche kürzeste Distanz zwischen den Knoten i und j eines Netzwerks bezeichnet .

2.4 Robustheit, Resilienz, Fehlertoleranz

In der Literatur zu komplexen Netzwerken werden die Begriffe Robustheit, Fehlertoleranz und Resilienz häufig gemeinsam verwendet, obwohl diese verschiedene

Schwerpunkte fokussieren . Im den folgenden Unterkapiteln wird eine Abgrenzung im Kontext von Stromnetzwerken vorgenommen, basierend auf der Übersichtsarbeit von Xiaoyu Qi und Gang Mei (2024).

2.4.1 Robustheit

Robustheit beschreibt die Fähigkeit eines Netzwerks, seine Strukturen und Funktionen trotz Störungen weitgehend gleichbleibend aufrechtzuerhalten . Robustheit kann als Teilaspekt von Resilienz betrachtet werden und bezieht sich hauptsächlich darauf, wie widerstandsfähig ein Netzwerk in seiner Struktur selbst gegenüber Störungen ist. Im Bereich von Stromnetzwerken, die zu den technologischen Netzwerken zählen, wird Robustheit als die Resistenz gegenüber Ausfällen bezeichnet. Der Kernfrage der Robustheit besteht darin, wie gut die Netzwerkfunktion unmittelbar nach einer Störung erhalten bleibt. In diesem Sinne gilt ein Stromnetz als robust, sofern der Ausfall eines einzelnen Umspannwerks keine weiterführenden Stromausfälle verursacht. Gemessen wird die Robustheit typischer Weise über die größte zusammenhängende Komponente (GCC). Hierbei werden nach und nach Knoten oder Kanten entweder zufällig oder gezielt aus dem Netzwerk entfernt und nach jedem Schritt die Größe des größten funktionierenden Netzteils gemessen :

$$\text{Rob} = \frac{1}{N} \sum_{q=1}^N S(q)$$

Wobei Rob die Gesamtrobustheit eines Netzwerks bezeichnet und $S(q)$ die relative Größe der größten Komponente nach q entfernten Knoten darstellt .

2.4.2 Fehlertoleranz

Die Fehlertoleranz bezeichnet die Fähigkeit eines Systems, trotz Fehler einzelner Komponenten weiterhin funktionsfähig zu bleiben und ohne die Fehler zwingend reparieren zu müssen. Während Stromnetze im Bereich der technologischen Netze angesiedelt sind, bezieht sich die Fehlertoleranz mehr auf Informationsnetzwerke , zu denen Kommunikations- und Internetnetzwerke zählen . Dabei wird stärker auf Hard- und Software Bezug genommen und die Fähigkeit beschrieben, Fehler strukturell oder algorithmisch zu kompensieren, z.B. durch Redundanzen oder Umleitung von Flüssen. Die Kernfrage der Fehlertoleranz ist, wie gut das System während eines auftretenden Fehlers weiterarbeiten kann. So gilt ein Stromnetz als fehlertolerant, wenn bei einem Leitungsausfall automatisch alternative Wege für den Stromfluss gewählt werden.

2.4.3 Resilienz

Die Resilienz umfasst die Widerstandsfähigkeit eines Netzwerks im Störfall, die Fähigkeit zur Begrenzung der Auswirkungen und die Fähigkeit zur Wiederaufnahme eines akzeptablen Funktionsniveaus. Dementsprechend ist die Resilienz ein übergreifendes Konzept, welches die Robustheit, Fehlertoleranz, Anpassungs- und Erholungsfähigkeit beinhaltet. Ein Smart Grid ist beispielsweise dann resilient, wenn es nach einem extremen Wetterereignis schnell wieder auf ein normales Versorgungsniveau zurückkehren kann. Gemessen werden kann die Resilienz anhand der Fläche unter der Leistungs-Zeit-Kurve:

$$\text{Res} = \int_{t_0}^{t_1} Q(t) dt$$

Wobei $Q(t)$ die Systemleistung relativ zur Norm ist und Res beschreibt, wie schnell und wie gut die Erholung erfolgt. Die Leistung kann die Konnektivität (GCC), Flusseffizienz, Versorgungsgrad oder Kommunikationsfähigkeit sein und kann berechnet werden durch

$$Q(t) = \frac{P(t)}{TP(t)}$$

, wobei $P(t)$ die gemessene und $TP(t)$ die Zielleistung ist, die ohne Störung zu erwarten wäre. Bei mehreren Messdurchgängen wird der Erwartungswert von

$$\frac{P(t)}{TP(t)}$$

(also der Mittelwert der Messdurchgänge) berechnet. Die Kernfrage der Resilienz ist, wie viel der ursprünglichen Leistung noch vorhanden ist.

3 Methodik und Versuchsdesign

3.1 Netzwerkmodelle

Die Untersuchung der Robustheit und Fehlertoleranz von Netzwerken erfordert eine bewusste Auswahl geeigneter Netzwerkmodelle. Hierbei ist das Ziel, sowohl abstrakte, kontrollierbare Strukturen als auch realitätsnahe Netze zu betrachten, um Unterschiede zwischen idealisierten Modellen und realen Infrastrukturen kenntlich machen zu können. In dieser Arbeit werden daher drei synthetische Netzwerkmodelle sowie ein reales Stromnetzmodell herangezogen.

Synthetische Netzwerkmodelle: Synthetische Netzwerke ermöglichen es, spezifische strukturelle Eigenschaften gezielt zu variieren und isoliert zu analysieren. Sie dienen als Referenz, um grundlegende Zusammenhänge zwischen Netzwerkstruktur und Robustheit systematisch zu untersuchen. Als Basismodell wird der Erdős–Rényi-Zufallsgraph verwendet. In diesem Modell werden n Knoten betrachtet, zwischen denen jede mögliche Kante mit einer festen Wahrscheinlichkeit p unabhängig von allen anderen Kanten existiert. Die entstehende Gradverteilung folgt näherungsweise einer Poisson-Verteilung. Erdős–Rényi-Netzwerke besitzen keine ausgeprägten Hubs und nur eine geringe lokale Clusterbildung. Dadurch eignen sie sich als Vergleichsmaßstab für Netzwerke ohne strukturelle Heterogenität.

Das Watts–Strogatz-Modell beschreibt Netzwerke mit Small-World-Eigenschaften, also Netzwerke, in denen die meisten Knoten über wenige Schritte erreichbar sind (kurze Pfade) und gleichzeitig lokale Cluster mit vielen Verbindungen untereinander existieren. Ausgangspunkt ist ein reguläres Ringgitter, in dem jeder Knoten mit k nächsten Nachbarn verbunden ist. Durch zufälliges Umverdrahten von Kanten mit einer Wahrscheinlichkeit p entstehen kurze mittlere Pfadlängen bei gleichzeitig erhöhtem Clustering. Diese Eigenschaften sind insbesondere für technische Infrastrukturnetze relevant, da sie Effizienz und strukturelle Redundanz kombinieren.

Das Barabási–Albert-Modell erzeugt skalenfreie Netzwerke mit einer potenzgesetzartigen Gradverteilung. Das Modell basiert auf wachsendem Netzwerkaufbau und bevorzugter Anbindung neuer Knoten an bereits stark vernetzte Knoten. Dadurch entstehen wenige hochgradige Knoten, sogenannte Hubs. Skalenfreie Netzwerke gelten als robust gegenüber zufälligen Ausfällen, zeigen jedoch eine ausgeprägte Anfälligkeit gegenüber gezielten Angriffen auf zentrale Knoten. Aufgrund dieser Eigenschaften ist dieses Modell besonders geeignet, um Worst-Case-Szenarien für Angriffe auf kritische Infrastrukturen zu untersuchen.

Reales Netzwerkmodell: Zur Ergänzung der synthetischen Modelle wird ein reales Stromnetz betrachtet. Als Datengrundlage dient das PyPSA-Eur-Projekt, das ein detailliertes Modell des europäischen Übertragungsnetzes bereitstellt. Die Netzdaten basieren auf öffentlich verfügbaren OpenStreetMap-Informationen und bilden Hochspannungsleitungen sowie Umspannwerke ab.

Für diese Arbeit werden die Netzkomponenten aus den Dateien `buses.csv` und `lines.csv` extrahiert. Um eine einheitliche Verarbeitung zu ermöglichen, werden die Daten in einen ungerichteten Graphen überführt und anschließend im GraphML-Format gespeichert. Dieses Format erlaubt eine direkte Weiterverarbeitung mit gängigen Graphbibliotheken.

Die aufbereiteten realen Netzwerke werden im Verzeichnis `data/real/` abgelegt, während die ursprünglichen PyPSA-Daten unter `data/pypsa/` gespeichert

bleiben. Das Laden und optionale Vorverarbeiten der realen Netze, etwa die Beschränkung auf die größte verbundene Komponente oder die Umnummerierung der Knoten, erfolgt zentral über die Projektmodule `src/graph_factory.py` und `src/real_network_loader.py`.

Begründung der Modellwahl Die Kombination aus synthetischen und realen Netzwerkmodellen ermöglicht einen strukturierten Vergleich zwischen theoretischen Idealmodellen und realen Infrastrukturen. Während synthetische Netze gezielte Aussagen über den Einfluss einzelner Strukturmerkmale erlauben, liefert das reale Stromnetz eine praxisnahe Referenz. Unterschiede im Robustheits- und Fehlertoleranzverhalten können so nicht nur quantitativ gemessen, sondern auch strukturell interpretiert werden. Diese Kombination bildet die Grundlage für die in den folgenden Abschnitten beschriebenen Störungsszenarien und Bewertungsmethoden.

3.2 Störungsszenarien

Zur Bewertung der Robustheit und Fehlertoleranz komplexer Netzwerke ist nicht nur die zugrunde liegende Topologie entscheidend, sondern auch die Art der betrachteten Störungen. Unterschiedliche Ausfallmechanismen können sehr unterschiedliche Auswirkungen auf die Netzwerkstruktur haben. In dieser Arbeit werden zwei grundlegende Klassen von Störungsszenarien untersucht: zufällige Ausfälle einzelner Knoten sowie gezielte Angriffe auf strukturell zentrale Knoten.

Zufällige Ausfälle (Random Failures) Zufällige Ausfälle modellieren Störungen, bei denen einzelne Netzkomponenten ohne systematische Auswahl ausfallen. Typische Ursachen sind technische Defekte, altersbedingte Ausfälle oder lokal begrenzte externe Einwirkungen. In der Simulation werden diese Szenarien durch eine zufällige Auswahl von Knoten realisiert, die schrittweise aus dem Netzwerk entfernt werden.

Formal wird der Ausfallgrad durch den Parameter $q \in [0, 1]$ beschrieben, der den Anteil der entfernten Knoten angibt. Für jeden Wert von q wird eine entsprechende Anzahl von Knoten zufällig ausgewählt und aus dem ursprünglichen Netzwerk entfernt. Anschließend werden die strukturellen Eigenschaften des verbleibenden Netzwerks analysiert.

Zufällige Ausfälle dienen in der Netzwerktheorie als Referenzszenario zur Bewertung der allgemeinen Fehlertoleranz. Insbesondere skalenfreie Netzwerke zeigen in diesem Fall häufig eine hohe Robustheit, da die Wahrscheinlichkeit gering ist,

dass hochgradige Knoten frühzeitig betroffen sind. Die Ergebnisse aus diesen Szenarien bilden daher eine wichtige Vergleichsbasis für gezielte Angriffsszenarien.

Gezielte Angriffe auf zentrale Knoten Gezielte Angriffe modellieren Störungen, bei denen bewusst solche Netzkomponenten entfernt werden, die für die Konnektivität oder den Fluss im Netzwerk von besonderer Bedeutung sind. Diese Szenarien sind insbesondere für kritische Infrastrukturen relevant, da der Ausfall weniger zentraler Knoten erhebliche strukturelle Schäden verursachen kann.

In dieser Arbeit werden zwei Formen gezielter Angriffe betrachtet. Beim gradbasierten Angriff werden Knoten in absteigender Reihenfolge ihres Knotengrads entfernt. Der Knotengrad beschreibt die Anzahl direkter Nachbarn eines Knotens und dient als einfaches Maß für lokale Vernetzung. Knoten mit hohem Grad fungieren häufig als Hubs, deren Entfernung zu einer schnellen Fragmentierung des Netzwerks führen kann.

Als zweite Angriffsklasse werden Angriffe auf Basis der Betweenness-Zentralität untersucht. Die Betweenness-Zentralität misst, wie häufig ein Knoten auf kürzesten Pfaden zwischen anderen Knoten liegt, und erfasst damit seine Bedeutung für den globalen Informations- oder Leistungsfluss. Knoten mit hoher Betweenness wirken häufig als Brücken zwischen ansonsten schwach verbundenen Teilstrukturen. Ihr Ausfall kann daher selbst bei moderatem Knotengrad zu einer Aufspaltung des Netzwerks führen.

Implementierung der Störungsszenarien Die Umsetzung der Störungsszenarien erfolgt modular innerhalb des Projekts. Die Bestimmung der Reihenfolge, in der Knoten entfernt werden, ist im Modul `src/attacks.py` realisiert. Für zufällige Ausfälle wird eine zufällige Permutation der Knotenliste erzeugt, während für gezielte Angriffe eine Sortierung nach dem jeweiligen Zentralitätsmaß erfolgt. Die eigentliche Simulation der Knotenentfernung wird im Modul `src/simulation.py` durchgeführt. Für jeden betrachteten Wert von q wird die entsprechende Anzahl von Knoten aus dem Netzwerk entfernt, bevor die definierten Metriken für das verbleibende Netzwerk berechnet werden. Die klare Trennung zwischen Angriffsauswahl und Simulation erleichtert die Nachvollziehbarkeit des Versuchsaufbaus und ermöglicht eine einfache Erweiterung um zusätzliche Angriffsszenarien.

Begründung der Szenarienauswahl Die Kombination aus zufälligen Ausfällen und gezielten Angriffen deckt ein breites Spektrum realistischer Störungsmechanismen ab. Zufällige Ausfälle erlauben Aussagen über die allgemeine Fehlertoleranz eines Netzwerks, während gezielte Angriffe Worst-Case-Szenarien abbilden. Der direkte Vergleich beider Szenarientypen macht strukturelle Schwächen sichtbar und erlaubt es, Unterschiede zwischen synthetischen Netzwerkmodellen und

realen Stromnetzen systematisch herauszuarbeiten.

3.3 Bewertungsmetriken

Zur quantitativen Bewertung der Robustheit und Fehlertoleranz der untersuchten Netzwerke werden mehrere komplementäre Metriken herangezogen. Ziel ist es, sowohl den strukturellen Zerfall des Netzwerks als auch dessen verbleibende Leistungsfähigkeit unter Störungen abzubilden. Die Auswahl der Metriken orientiert sich an etablierten Ansätzen der Netzwerktheorie und an deren praktischer Anwendbarkeit im Kontext von Infrastrukturnetzen.

Größte verbundene Komponente (GCC) Eine zentrale Kenngröße zur Bewertung der strukturellen Integrität eines Netzwerks ist die Größe der größten verbundenen Komponente (Greatest Connected Component, GCC). Sie beschreibt die Anzahl der Knoten, die nach einer Störung weiterhin miteinander verbunden sind. Zur Vergleichbarkeit zwischen Netzwerken unterschiedlicher Größe wird die GCC häufig relativ zur ursprünglichen Knotenzahl betrachtet.

Formal wird die normierte Größe der größten verbundenen Komponente als

$$S(q) = \frac{|GCC(q)|}{N}$$

definiert, wobei N die ursprüngliche Anzahl der Knoten und q der Anteil der entfernten Knoten ist. Sinkt $S(q)$ stark ab, deutet dies auf eine Fragmentierung des Netzwerks hin. Diese Metrik ist besonders geeignet, um strukturelle Zusammenbrüche zu identifizieren und wird in zahlreichen Arbeiten zur Robustheitsanalyse verwendet.

Robustheitskurven Die Robustheitskurve beschreibt den Verlauf der normierten Größe der größten verbundenen Komponente $S(q)$ in Abhängigkeit vom Anteil der entfernten Knoten q . Sie stellt somit den schrittweisen Strukturverlust eines Netzwerks unter zunehmender Störung dar.

Robustheitskurven erlauben einen direkten Vergleich unterschiedlicher Netzwerke und Angriffsszenarien. Flach verlaufende Kurven deuten auf eine hohe Robustheit hin, während ein steiler Abfall auf eine starke Verwundbarkeit schließen lässt. Beide Fälle sind schematisch in Abbildung ?? dargestellt. In der vorliegenden Arbeit werden Robustheitskurven für zufällige Ausfälle sowie für gezielte Angriffe berechnet und gegenübergestellt.

Die Berechnung und Visualisierung der Robustheitskurven erfolgt projektintern

im Modul `src/analysis.py`, wobei die benötigten Rohdaten aus den Simulationsergebnissen aggregiert werden.

Fläche unter der Robustheitskurve (AUC) Zur Verdichtung der Robustheitskurven auf eine einzelne skalare Kennzahl wird die Fläche unter der Robustheitskurve (Area Under the Curve, AUC) berechnet. Sie entspricht dem Integral von $S(q)$ über den betrachteten Bereich von q und kann als globales Robustheitsmaß interpretiert werden.

Ein hoher AUC-Wert weist darauf hin, dass ein großer Teil des Netzwerks auch bei fortschreitender Knotenentfernung erhalten bleibt. Umgekehrt signalisiert ein niedriger AUC-Wert eine hohe Anfälligkeit gegenüber Störungen. Die AUC erlaubt somit eine kompakte quantitative Bewertung der Robustheit und eignet sich insbesondere für den Vergleich unterschiedlicher Netzwerke oder Angriffsszenarien.

Strukturelle Ergänzungsmetriken Neben der Größe der größten verbundenen Komponente werden weitere strukturelle Metriken betrachtet, um das Robustheitsverhalten genauer einzuordnen. Dazu zählen insbesondere der Clustering-Koeffizient und der Durchmesser des Netzwerks.

Der Clustering-Koeffizient misst den Grad lokaler Vernetzung und dient als Indikator für strukturelle Redundanz. Ein hoher Clustering-Wert kann auf alternative Pfade hinweisen, die zur Fehlertoleranz beitragen. In dieser Arbeit werden sowohl der globale Clustering-Koeffizient als auch der mittlere lokale Clustering-Koeffizient berechnet.

Der Durchmesser beschreibt die maximale kürzeste Pfadlänge zwischen zwei Knoten innerhalb der größten verbundenen Komponente. Ein stark ansteigender Durchmesser im Verlauf der Simulation deutet darauf hin, dass das Netzwerk zwar noch verbunden ist, jedoch an Effizienz verliert. Der Durchmesser ergänzt damit die GCC-basierte Analyse um eine Aussage zur erreichbaren Netzwerkleistung.

Implementierung der Metriken Die Berechnung der beschriebenen Metriken erfolgt zentral im Modul `src/metrics.py`. Dieses Modul kapselt alle Metrikfunktionen und stellt sicher, dass sie konsistent für synthetische und reale Netzwerke angewendet werden. Die Aggregation der Ergebnisse sowie die Berechnung der AUC erfolgen in `src/analysis.py`. Durch diese Trennung zwischen Simulation und Auswertung wird eine klare Struktur geschaffen, die sowohl die Nachvollziehbarkeit als auch die Erweiterbarkeit des Projekts unterstützt.




Abbildung 1: Vergleich topologischer Netzwerkmodelle. Von links nach rechts: Erdős-Rényi-Zufallsgraph (homogene Struktur), Watts-Strogatz-Small-World-Netzwerk (hohe lokale Clusterbildung) und Barabási-Albert-skalenfreies Netzwerk (markante Hub-Struktur).




Abbildung 2: Schematische Darstellung von Robustheitskurven für ein robustes und ein fragiles Netzwerk.

3.4 Versuchsprotokoll

Um die Robustheit unterschiedlicher Netzwerke vergleichbar zu untersuchen, wird ein einheitliches und reproduzierbares Versuchsprotokoll verwendet. Dieses legt fest, wie Störungen simuliert werden, in welchen Schritten Knoten entfernt werden und wie die Ergebnisse aggregiert und gespeichert werden. Ziel ist es, zufällige Effekte zu kontrollieren und belastbare Aussagen über strukturelle Unterschiede zwischen den Netzwerken zu ermöglichen.

Anzahl der Wiederholungen Da insbesondere zufällige Ausfälle und zufällige Netzgenerierung stochastischen Schwankungen unterliegen, werden Simulationen mehrfach wiederholt. Für jedes Netzwerkmodell und jedes Störungsszenario werden mehrere unabhängige Instanzen erzeugt und ausgewertet. Die Anzahl der Wiederholungen ist dabei konfigurierbar und wird in den jeweiligen Szenariodateien festgelegt. Die Wiederholungen dienen dazu, zufällige Ausreißer zu glätten und Mittelwerte über mehrere Läufe zu bilden. Dies ist insbesondere bei Erdős-Rényi- und Barabási-Albert-Netzwerken relevant, da bereits kleine strukturelle Unterschiede zwischen einzelnen Instanzen das Robustheitsverhalten beeinflussen können. Die Aggregation über mehrere Läufe erhöht somit die statistische Aussagekraft der Ergebnisse.

Schrittweite der Knotenentfernung Die Entfernung von Knoten erfolgt schrittweise in Abhängigkeit vom Ausfallparameter q , der den Anteil der entfernten Knoten beschreibt. Die Schrittweite von q bestimmt die Auflösung der Robustheitskurven. Kleine Schrittweiten ermöglichen eine feinere Analyse des Netzwerkzerfalls, erhöhen jedoch den Rechenaufwand.

In der vorliegenden Arbeit werden typische Schrittweiten zwischen 0,02 und 0,05 verwendet. Diese stellen einen Kompromiss zwischen Rechenzeit und analytischer Genauigkeit dar. Die konkreten Werte werden in den jeweiligen Konfigurationsdateien definiert und können für einzelne Experimente angepasst werden.

Aggregation der Ergebnisse Die Simulationsergebnisse werden für jeden betrachteten Wert von q , jedes Angriffsszenario und jede Netzwerkinstanz separat erfasst. Zur Auswertung werden diese Rohdaten anschließend aggregiert. Dabei werden für jede Kombination aus Netzwerktyp und Angriffsszenario Mittelwerte über alle Wiederholungen gebildet.

Die Aggregation erfolgt insbesondere für die Größe der größten verbundenen Komponente, aus der die Robustheitskurven $S(q)$ abgeleitet werden. Auf Basis dieser aggregierten Kurven wird anschließend die Fläche unter der Kurve (AUC) berechnet. Dieses Vorgehen stellt sicher, dass die Robustheitsbewertung nicht

von einzelnen zufälligen Realisierungen dominiert wird.

Reproduzierbarkeit und Zufallsstartwerte Ein zentrales Ziel des Versuchsprotokolls ist die vollständige Reproduzierbarkeit aller Simulationen. Zu diesem Zweck werden alle zufallsbasierten Prozesse durch explizite Zufallsstartwerte (Seeds) gesteuert. Dazu zählen sowohl die Generierung synthetischer Netzwerke als auch die Auswahl zufälliger Ausfallreihenfolgen bei Random-Failure-Szenarien. Die verwendeten Seeds werden in den jeweiligen Konfigurationsdateien festgelegt. Dadurch kann jede Simulation exakt reproduziert werden, sofern dieselben Konfigurationsdateien und dieselbe Softwareversion verwendet werden. Dieses Vorgehen ist insbesondere für den Vergleich von Ergebnissen und für eine spätere Nachvollziehbarkeit der Experimente von Bedeutung.

Konfigurations- und Ergebnisstruktur Alle experimentellen Parameter werden über YAML-basierte Konfigurationsdateien im Verzeichnis `configs/` definiert. Diese enthalten unter anderem Angaben zu Netzwerkmodellen, Angriffsszenarien, Schrittweiten, Metriken und Wiederholungszahlen. Durch diese Trennung von Konfiguration und Code können neue Experimente ohne Anpassung der Implementierung durchgeführt werden.

Die Ergebnisse der Simulationen werden strukturiert im Verzeichnis `results/` abgelegt. Für jedes Experiment wird ein eigener Unterordner erzeugt, der sowohl die Rohdaten der Simulationen als auch aggregierte Auswertungen enthält. Dieses Vorgehen erleichtert die systematische Analyse der Ergebnisse und bildet die Grundlage für die in Kapitel 5 dargestellten Resultate.

4 Implementierung

4.1 Werkzeuge und Bibliotheken

Die Implementierung des praktischen Teils basiert auf einer modularen Softwarearchitektur in Python. Ziel war es, ein flexibles, reproduzierbares und erweiterbares Analysewerkzeug zu entwickeln, das sowohl synthetische als auch reale Netzwerke verarbeiten kann. Die Auswahl der verwendeten Werkzeuge und Bibliotheken orientiert sich an ihrer Verbreitung in der wissenschaftlichen Praxis sowie an ihrer Eignung für die Analyse komplexer Netzwerke.

Programmiersprache Python Als Programmiersprache wird Python eingesetzt. Python bietet eine gute Balance zwischen Ausdruckstärke, Lesbarkeit und Verfügbarkeit wissenschaftlicher Bibliotheken. Insbesondere für explorative Analysen, Simulationen und datengetriebene Auswertungen ist Python im Bereich der Netzwerkanalyse weit verbreitet. Die Implementierung legt Wert auf klare Modulgrenzen und eine nachvollziehbare Struktur, sodass der Code auch für Dritte leicht verständlich bleibt.

NetworkX Die zentrale Bibliothek für die Modellierung und Analyse der Netzwerke ist NetworkX. Sie stellt grundlegende Datenstrukturen für Graphen bereit und bietet eine Vielzahl effizient implementierter Algorithmen zur Berechnung von Netzwerkmetriken. Dazu zählen unter anderem kürzeste Pfade, Zentralitätsmaße, Clustering-Koeffizienten sowie Funktionen zur Bestimmung verbundener Komponenten.

Im Projekt wird NetworkX sowohl für die Erzeugung synthetischer Netzwerke als auch für die Verarbeitung realer Netze verwendet. Durch die einheitliche Graphrepräsentation können alle Analyse- und Simulationsschritte unabhängig vom Ursprung des Netzwerks durchgeführt werden.

Datenformate und Dateiverarbeitung Zur Speicherung realer Netzwerke wird das GraphML-Format verwendet. GraphML ist ein XML-basiertes Austauschformat für Graphstrukturen und wird direkt von NetworkX unterstützt. Dadurch entfällt die Notwendigkeit eigener Parser oder Konvertierungsroutinen innerhalb der Simulation. Reale Netzwerke, wie das aus PyPSA-Eur abgeleitete Stromnetz, können so direkt in die Analysepipeline integriert werden.

Konfigurationsdateien werden im YAML-Format abgelegt. YAML ermöglicht eine übersichtliche und hierarchische Beschreibung experimenteller Parameter und ist auch für größere Konfigurationen gut lesbar. Die vollständige Parametrisie-

rung der Experimente erfolgt über diese Dateien, wodurch Änderungen an den Versuchsbedingungen ohne Anpassung des Programmcodes möglich sind.

Streamlit für die grafische Benutzeroberfläche Zur interaktiven Exploration der Simulationsergebnisse wird Streamlit eingesetzt. Streamlit erlaubt es, mit vergleichsweise geringem Implementierungsaufwand eine grafische Benutzeroberfläche zu erstellen, die direkt mit dem Python-Code verbunden ist. Die Benutzeroberfläche dient insbesondere dazu, Parameter zu variieren, Simulationen zu starten und Ergebnisse visuell auszuwerten.

Ein besonderer Fokus liegt auf der dynamischen Visualisierung der Netzwerkstruktur während des Simulationsverlaufs. Hierbei werden Knoten und Kanten des Netzwerks grafisch dargestellt, sodass der schrittweise Zerfall der Netzwerkstruktur unmittelbar sichtbar wird. Diese visuelle Komponente ergänzt die numerischen Auswertungen und erleichtert das intuitive Verständnis der Robustheitsphänomene.

Weitere Hilfsbibliotheken Zur numerischen Verarbeitung und Auswertung der Simulationsergebnisse werden zusätzliche Standardbibliotheken eingesetzt. NumPy dient zur effizienten Verarbeitung numerischer Daten, während Pandas für das Speichern, Aggregieren und Weiterverarbeiten der Simulationsergebnisse in Tabellenform verwendet wird. Matplotlib wird zur Erstellung statischer Plots genutzt, etwa für Robustheitskurven oder Gradverteilungen außerhalb der interaktiven Oberfläche.

Begründung der Werkzeugwahl Die Kombination der genannten Werkzeuge ermöglicht eine klare Trennung zwischen Modellierung, Simulation, Auswertung und Visualisierung. Gleichzeitig bleibt das Projekt leichtgewichtig und vollständig auf Open-Source-Komponenten aufgebaut. Dies unterstützt sowohl die Reproduzierbarkeit der Ergebnisse als auch die Nachvollziehbarkeit der Implementierung, was insbesondere im akademischen Kontext von zentraler Bedeutung ist.

4.2 Softwarearchitektur und Modulaufbau

Die Software ist modular aufgebaut und folgt einer klaren Trennung zwischen Konfiguration, Netzwerkgenerierung, Simulation, Auswertung und Visualisierung. Ziel dieser Struktur ist es, die einzelnen Arbeitsschritte der Analyse nachvollziehbar zu isolieren und gleichzeitig eine flexible Erweiterbarkeit zu ermöglichen, gemäß dem Softwaredesignprinzip Separation of Concerns (SoC). Die Architektur

orientiert sich dabei nicht an klassischen Software-Frameworks, sondern an der logischen Abfolge eines experimentellen Workflows.

Gesamtstruktur des Projekts Das Projekt ist in mehrere Hauptverzeichnisse gegliedert. Der Quellcode befindet sich im Verzeichnis `src/`, während Konfigurationsdateien unter `configs/` abgelegt sind. Eingabedaten für reale Netzwerke werden in `data/` gespeichert, wobei eine Trennung zwischen Rohdaten und aufbereiteten Graphdateien vorgenommen wird. Simulationsergebnisse werden strukturiert im Verzeichnis `results/` abgelegt. Diese Trennung ermöglicht es, Konfigurationen, Daten und Code unabhängig voneinander zu verändern. Insbesondere können neue Experimente durch das Hinzufügen oder Anpassen von YAML-Dateien definiert werden, ohne dass Änderungen an der Implementierung erforderlich sind.




Abbildung 3: Architektur des Simulationsprojekts. Die Simulation wird vollständig über Konfigurationsdateien gesteuert und modular in Netzwerkgenerierung, Angriffsszenarien, Metrikberechnung und Ergebnisverarbeitung unterteilt.

Konfigurations- und Steuerungsebene Die Konfiguration der Experimente erfolgt vollständig über YAML-Dateien. Das Laden und Validieren dieser Konfigurationen wird durch das Modul `src/config_loader.py` realisiert. Dieses Modul

stellt sicher, dass alle benötigten Parameter vorhanden sind und in einer einheitlichen internen Struktur an die weiteren Komponenten des Systems übergeben werden.

Die zentrale Steuerung eines Experiments erfolgt über das Modul `src/simulation.py`. Dieses Modul koordiniert den gesamten Ablauf eines Simulationslaufs, beginnend bei der Netzwerkgenerierung über die Anwendung der Störungsszenarien bis hin zur Berechnung der Metriken und dem Speichern der Ergebnisse. Dadurch fungiert `simulation.py` als verbindende Schicht zwischen den einzelnen Funktionsmodulen.

Netzwerkgenerierung und Datenanbindung Die Erzeugung synthetischer Netzwerke ist im Modul `src/network_models.py` implementiert. Dort sind die verschiedenen Netzwerkmodelle (Erdős–Rényi, Watts–Strogatz, Barabási–Albert) gekapselt, sodass sie über eine einheitliche Schnittstelle instanziiert werden können. Für reale Netzwerke wird ein separater Ladepfad verwendet.

Das Modul `src/real_network_loader.py` übernimmt das Einlesen von GraphML-Dateien sowie optionale Vorverarbeitungsschritte, etwa die Beschränkung auf die größte verbundene Komponente oder die Umnummerierung der Knoten. Die Auswahl, ob ein synthetisches oder reales Netzwerk erzeugt wird, erfolgt zentral über das Modul `src/graph_factory.py`, das als Abstraktionsschicht zwischen Konfiguration und konkreter Netzwerkgenerierung dient.

Störungsszenarien und Angriffsauswahl Die Definition der Störungsszenarien ist im Modul `src/attacks.py` umgesetzt. Dieses Modul berechnet für ein gegebenes Netzwerk die Reihenfolge, in der Knoten im Rahmen eines bestimmten Angriffsszenarios entfernt werden sollen. Dabei werden sowohl zufällige Ausfälle als auch gezielte Angriffe auf Basis von Zentralitätsmaßen unterstützt.

Durch die Auslagerung der Angriffsauswahl in ein eigenes Modul wird eine klare Trennung zwischen der Definition der Störung und ihrer Anwendung erreicht. Neue Angriffsszenarien können so implementiert werden, ohne den Ablauf der Simulation selbst verändern zu müssen.

Metrikberechnung und Analyse Die Berechnung aller strukturellen Metriken erfolgt im Modul `src/metrics.py`. Dieses Modul enthält Funktionen zur Bestimmung der Größe der größten verbundenen Komponente, von Clustering-Koeffizienten, Durchmesser, Effizienz und weiteren Kenngrößen. Die Metrikt Funktionen sind bewusst unabhängig von der Simulation implementiert, sodass sie auch isoliert auf einzelne Netzwerke angewendet werden können.

Die weiterführende Auswertung der Simulationsergebnisse, insbesondere die Aggregation über mehrere Wiederholungen sowie die Berechnung der Robustheits-

kennzahlen wie der Fläche unter der Robustheitskurve, erfolgt im Modul `src/analysis.py`. Diese Trennung erleichtert eine saubere Nachvollziehbarkeit der einzelnen Verarbeitungsschritte.

Visualisierung und Benutzeroberfläche Die grafische Benutzeroberfläche ist im Verzeichnis `app/` umgesetzt und basiert auf Streamlit. Die Datei `streamlit_app.py` verbindet die Konfigurations-, Simulations- und Analysekomponenten zu einer interaktiven Oberfläche. Neben tabellarischen und grafischen Auswertungen wird dort auch eine dynamische Visualisierung der Netzwerkstruktur realisiert, die den schrittweisen Zerfall des Netzwerks während der Simulation sichtbar macht. Die eigentliche Logik zur dynamischen Netzvisualisierung ist im Modul `src/dynamic_visualization.py` gekapselt. Dadurch bleibt die Benutzeroberfläche übersichtlich, während die Visualisierungslogik unabhängig weiterentwickelt werden kann.

Architektonische Einordnung Die gewählte Architektur folgt keinem monolithischen Ansatz, sondern orientiert sich an der logischen Trennung der experimentellen Aufgaben. Diese Struktur unterstützt sowohl die Erweiterbarkeit des Projekts als auch dessen Verständlichkeit. Gleichzeitig bleibt die Implementierung bewusst einfach gehalten, um den Fokus auf die inhaltliche Analyse der Netzwerke und nicht auf komplexe Softwarearchitektur zu legen.

4.3 Reproduzierbarkeit und Konfigurationsmanagement

Ein zentrales Ziel der Implementierung ist die vollständige Reproduzierbarkeit aller durchgeführten Experimente. Da die Analyse komplexer Netzwerke sowohl stochastische Prozesse als auch zufallsbasierte Netzgenerierung umfasst, ist ein transparentes und konsistentes Konfigurationsmanagement notwendig. Dieses wird im Projekt durch eine klare Trennung von Code, Konfiguration und Ergebnissen realisiert.

Konfigurationsdateien Alle experimentellen Parameter werden ausschließlich über YAML-basierte Konfigurationsdateien im Verzeichnis `configs/` definiert. Diese Dateien enthalten sämtliche Informationen zur Beschreibung eines Experiments, darunter die Auswahl der Netzwerkmodelle, deren Parametrisierung, die betrachteten Störungsszenarien, die Schrittweite der Knotenentfernung sowie die zu berechnenden Metriken.

Durch diese Auslagerung der Konfiguration aus dem Programmcode können neue Experimente definiert oder bestehende Experimente variiert werden, ohne Än-

derungen an der Implementierung vornehmen zu müssen. Gleichzeitig bleibt die vollständige Beschreibung eines Experiments in einer einzelnen Datei nachvollziehbar dokumentiert.

Zufallsstartwerte und deterministisches Verhalten Zur Kontrolle stochastischer Einflüsse werden alle zufallsbasierten Prozesse durch explizite Zufallsstartwerte (Seeds) gesteuert. Diese betreffen sowohl die Generierung synthetischer Netzwerke als auch die Auswahl zufälliger Ausfallreihenfolgen bei Random-Failure-Szenarien. Die verwendeten Seeds sind Bestandteil der jeweiligen Konfigurationsdateien.

Durch dieses Vorgehen ist sichergestellt, dass identische Konfigurationsdateien bei mehrfacher Ausführung zu denselben Netzwerken, Ausfallreihenfolgen und Simulationsergebnissen führen. Dies ermöglicht nicht nur eine zuverlässige Reproduktion der Ergebnisse, sondern auch einen gezielten Vergleich einzelner Parameteränderungen.

Ergebnisstruktur und Versionierung Die Ergebnisse der Simulationen werden automatisiert im Verzeichnis `results/` abgelegt. Für jedes Experiment wird ein eigener Unterordner erzeugt, der sowohl die Rohdaten der einzelnen Simulationsläufe als auch aggregierte Auswertungen enthält. Die Dateinamen enthalten den Namen des Experiments, sodass eine eindeutige Zuordnung zwischen Konfiguration und Ergebnisdaten möglich ist.

Die Speicherung der Ergebnisse in tabellarischer Form ermöglicht eine spätere Weiterverarbeitung, etwa für zusätzliche Analysen oder externe Visualisierungen. In Kombination mit einer Versionsverwaltung des Quellcodes lassen sich so auch ältere Ergebnisse eindeutig einem bestimmten Stand der Implementierung zuordnen.

Nachvollziehbarkeit des Experimentablaufs Durch die Kombination aus konfigurationsbasierter Steuerung, deterministischer Simulation und strukturierter Ergebnisablage ist der gesamte Experimentablauf transparent nachvollziehbar. Jeder Schritt von der Definition der Parameter bis zur Auswertung der Ergebnisse lässt sich rekonstruieren. Dieses Vorgehen entspricht gängigen wissenschaftlichen Standards und stellt sicher, dass die im Rahmen dieser Arbeit präsentierten Ergebnisse überprüfbar und reproduzierbar sind.

5 Ergebnisse

5.1 Topologische Eigenschaften der untersuchten Netzwerke

Bevor die Robustheit der Netzwerke unter Störungen analysiert wird, ist es sinnvoll, die grundlegenden topologischen Eigenschaften der betrachteten Netzwerke zu vergleichen. Diese Eigenschaften bestimmen maßgeblich, wie ein Netzwerk auf Knotenentfernungen reagiert. Die Analyse bezieht sich auf den Ausgangszustand der Netzwerke ohne Knotenentfernung ($q = 0$), der in den Simulationsdaten explizit enthalten ist.

Untersucht werden drei synthetische Netzwerkmodelle: ein Erdős–Rényi-Zufallsgraph (ER), ein Watts–Strogatz-Small-World-Netzwerk (WS) und ein Barabási–Albert-Netzwerk (BA). Alle Netzwerke besitzen dieselbe Knotenzahl ($n = 800$), wodurch strukturelle Unterschiede direkt vergleichbar sind.

Gradstruktur und Vernetzung Die drei Modelle unterscheiden sich deutlich in ihrer Gradstruktur. Der Erdős–Rényi-Graph weist eine relativ homogene Gradverteilung auf: die meisten Knoten besitzen einen ähnlichen Grad, extreme Abweichungen sind selten. Das Watts–Strogatz-Netzwerk ist ebenfalls vergleichsweise homogen, besitzt aber durch seine Ausgangsringstruktur eine deutlich stärkere lokale Vernetzung. Beim Barabási–Albert-Netzwerk ist die Gradverteilung stark heterogen: wenige Knoten fungieren als Hubs mit sehr hohem Grad, während der Großteil nur schwach vernetzt ist. Diese Hub-Struktur ist für skalenfreie Netze typisch und wirkt sich später stark auf die Robustheit unter gezielten Angriffen aus.

Clustering und lokale Struktur Ein zentraler Unterschied zeigt sich im Clustering. Das Watts–Strogatz-Netzwerk besitzt sowohl einen hohen globalen Clustering-Wert als auch hohe mittlere lokale Clustering-Koeffizienten. Das bestätigt die typische Small-World-Logik: lokal dicht, global trotzdem kurze Wege. Der Erdős–Rényi-Graph hat dagegen nur geringe Clustering-Werte; lokale Dreiecke entstehen hier eher zufällig. Das Barabási–Albert-Netzwerk liegt dazwischen: es kann lokal durchaus Clustering zeigen, jedoch ungleich verteilt (oft stärker um zentrale Knoten herum).

Pfadlängen und Durchmesser Mittlere kürzeste Pfadlänge und Durchmesser geben einen Eindruck der globalen Erreichbarkeit. Erdős–Rényi und Watts–Strogatz zeigen im Ausgangszustand kurze mittlere Pfadlängen. Beim Watts–Strogatz-Modell ist interessant, dass diese kurzen Wege trotz hoher lokaler Struktur entstehen. Das Barabási–Albert-Netz weist ebenfalls kurze Pfadlängen auf,

was vor allem an den Hubs liegt, über die viele kürzeste Wege laufen. Der Durchmesser ist dabei ein empfindlicherer Indikator: er bleibt oft moderat, kann aber bei strukturellen Eingriffen schnell ansteigen, wenn zentrale Vermittlerknoten verloren gehen.

Einordnung für die Robustheitsanalyse Diese topologischen Unterschiede bilden die Ausgangslage für die folgenden Robustheitsanalysen. Homogene Gradverteilungen (ER, teilweise WS) sprechen für eine gleichmäßigere Reaktion auf zufällige Ausfälle. Hohe lokale Clusterbildung (WS) deutet auf Redundanz im Nahbereich hin. Die Hub-Struktur (BA) lässt hingegen eine starke Robustheit bei Random Failures, aber eine hohe Verwundbarkeit bei gezielten Angriffen erwarten. Ob und wie deutlich sich das in den Simulationen zeigt, wird in den nächsten Unterabschnitten mit Robustheitskurven und AUC-Kennzahlen überprüft.

5.2 Robustheit unter zufälligen Ausfällen

In diesem Abschnitt wird das Robustheitsverhalten der untersuchten Netzwerkmodelle unter zufälligen Knotenausfällen analysiert. Zufällige Ausfälle modellieren Störungen ohne gezielte Auswahl einzelner Knoten, wie sie etwa durch technische Defekte oder lokale externe Einwirkungen auftreten können. Zur Bewertung wird die Konnektivität der verbleibenden Netzwerke in Abhängigkeit vom Anteil entfernter Knoten betrachtet.

Als zentrale Metrik wird die Größe der größten verbundenen Komponente relativ zur Anzahl der verbleibenden Knoten verwendet,

$$S_{surv}(q) = \frac{|GCC(q)|}{N - n_{removed}(q)}.$$

Diese Normalisierung erlaubt es, Fragmentierungseffekte von dem trivialen Effekt der Knotenentfernung zu trennen und die strukturelle Kohärenz unter den verbleibenden Knoten gezielt zu untersuchen.

Abbildung ?? zeigt die resultierenden Robustheitskurven für Erdős–Rényi-, Watts–Strogatz- und Barabási–Albert-Netzwerke. Für kleine und mittlere Ausfallgrade bleibt die Konnektivität in allen drei Modellen nahezu vollständig erhalten. Erst bei hohen Werten von q kommt es zu einer deutlichen Fragmentierung der Netzwerke.

Zwischen den Modellen lassen sich dennoch systematische Unterschiede erkennen. Das Erdős–Rényi-Netzwerk weist über einen großen Bereich von q die höchste Konnektivität unter den verbleibenden Knoten auf. Die Fragmentierung setzt hier erst relativ spät ein. Das Watts–Strogatz-Netzwerk zeigt demgegenüber einen

früheren und steileren Abfall von $S_{surv}(q)$. Trotz hoher lokaler Clusterbildung führen zufällige Ausfälle bei größeren Ausfallgraden schneller zu einer Aufspaltung des Netzwerks. Das Barabási–Albert-Netzwerk nimmt eine Zwischenposition ein: Die Konnektivität bleibt zunächst stabil, sinkt jedoch bei hohen Ausfallgraden stärker als im Erdős–Rényi-Fall.

Insgesamt zeigt sich, dass unter zufälligen Ausfällen alle betrachteten Netzwerkmodelle eine vergleichsweise hohe Robustheit aufweisen. Die beobachteten Unterschiede sind moderat und treten überwiegend erst bei großen Ausfallgraden auf. Dieses Ergebnis steht im Einklang mit theoretischen Erwartungen und unterstreicht, dass zufällige Störungen allein nur begrenzt geeignet sind, um strukturelle Verwundbarkeiten deutlich sichtbar zu machen. Eine wesentlich stärkere Differenzierung ist bei gezielten Angriffen zu erwarten, die im folgenden Abschnitt untersucht werden.




Abbildung 4: Konnektivität der verbleibenden Knoten unter zufälligen Knotenausfällen. Dargestellt ist die normierte Größe der größten verbundenen Komponente relativ zur Anzahl der verbleibenden Knoten $S_{surv}(q) = |GCC(q)| / (N - n_{removed})$.

5.3 Robustheit unter gezielten Angriffen

In diesem Abschnitt wird das Robustheitsverhalten der untersuchten Netzwerke unter gezielten Angriffen analysiert. Im Gegensatz zu zufälligen Ausfällen werden hierbei Knoten nicht zufällig, sondern anhand struktureller Zentralitätsmaße entfernt. Solche Szenarien modellieren bewusste Angriffe auf kritische Netzkomponenten und stellen eine Worst-Case-Betrachtung der Netzwerkstabilität dar. Untersucht werden zwei Angriffstypen: gezielte Angriffe auf Basis des Knotengrads sowie auf Basis der Betweenness-Zentralität. In beiden Fällen werden Knoten iterativ in absteigender Reihenfolge des jeweiligen Zentralitätsmaßes entfernt.

Gradbasierte Angriffe Abbildung ?? zeigt die Robustheitskurven unter gradbasierten Angriffen. Die Unterschiede zwischen den Netzwerkmodellen sind in diesem Szenario besonders deutlich ausgeprägt. Das Barabási–Albert-Netzwerk reagiert extrem empfindlich auf die gezielte Entfernung hochgradiger Knoten. Bereits bei kleinen Anteilen entfernter Knoten bricht die größte verbundene Komponente nahezu vollständig zusammen.

Ursächlich hierfür ist die ausgeprägte Hub-Struktur skalenfreier Netzwerke. Die Entfernung weniger zentraler Knoten führt dazu, dass große Teile des Netzwerks ihre Anbindung verlieren. Erdős–Rényi- und Watts–Strogatz-Netzwerke zeigen demgegenüber eine deutlich höhere Robustheit. Aufgrund ihrer homogenen Gradverteilungen erfolgt die Fragmentierung hier schrittweise und erst bei höheren Angriffsstärken.

Angriffe nach Betweenness-Zentralität Die Auswirkungen gezielter Angriffe auf Basis der Betweenness-Zentralität sind in Abbildung ?? dargestellt. Auch in diesem Szenario zeigt das Barabási–Albert-Netzwerk eine ausgeprägte Verwundbarkeit. Die Entfernung weniger Knoten mit hoher Vermittlungsfunktion führt rasch zu einer Fragmentierung des Netzwerks.

Auffällig ist zudem das Verhalten des Watts–Strogatz-Netzwerks. Trotz hoher lokaler Clusterbildung reagieren diese Netzwerke empfindlich auf Betweenness-basierte Angriffe, da einzelne Knoten eine zentrale Rolle für die Verbindung verschiedener Netzwerkbereiche einnehmen. Erdős–Rényi-Netzwerke weisen auch in diesem Szenario die höchste Robustheit auf, da keine einzelnen Knoten eine dominierende Vermittlungsfunktion besitzen.

Zusammenfassende Einordnung Der Vergleich beider Angriffsszenarien zeigt, dass gezielte Angriffe die Netzwerkstruktur wesentlich stärker beeinträchtigen als zufällige Ausfälle. Insbesondere skalenfreie Netzwerke, die unter Random Failures als robust gelten, erweisen sich unter gezielten Angriffen als hochgradig




Abbildung 5: Robustheitskurven der untersuchten Netzwerkmodelle unter gezielten Angriffen auf Basis des Knotengrads.




Abbildung 6: Robustheitskurven der untersuchten Netzwerkmodelle unter gezielten Angriffen auf Basis der Betweenness-Zentralität.

verwundbar. Die Simulationen bestätigen damit zentrale theoretische Befunde und verdeutlichen, dass strukturelle Zentralität ein entscheidender Faktor für die Stabilität komplexer Netzwerke ist.

5.4 Zusammenfassender Robustheitsvergleich mittels AUC

Die bisherigen Abschnitte haben das Robustheitsverhalten der Netzwerke anhand von Kurvenverläufen illustriert. Für einen kompakten und vergleichbaren Gesamtüberblick wird im Folgenden die Fläche unter der Robustheitskurve (Area Under the Curve, AUC) betrachtet. Als zugrunde liegende Größe dient dabei

$$S(q) = \frac{|GCC(q)|}{N},$$

also der relative Anteil der größten verbundenen Komponente in Abhängigkeit vom entfernten Knotenanteil q . Die AUC fasst den gesamten Kurvenverlauf zu einer einzigen Kennzahl zusammen und erlaubt damit einen direkten quantitativen Vergleich zwischen Netzwerken und Angriffsszenarien.

Tabelle 1: AUC der Robustheitskurven (größere Werte $\Rightarrow$ höhere Robustheit).

Netzwerk	Random Failures	Targeted (Degree)	Targeted (Betweenness)
BA_n800_m3	0.454	0.196	0.210
ER_n800_p0.01	0.476	0.408	0.407
WS_n800_k8_p0.1	0.454	0.418	0.375

Random Failures Unter zufälligen Ausfällen zeigen alle drei synthetischen Netzwerkmodelle vergleichsweise hohe AUC-Werte. Das Erdős–Rényi-Netzwerk weist mit $AUC \approx 0,48$ die höchste Robustheit auf, gefolgt von Watts–Strogatz und Barabási–Albert mit nahezu identischen Werten von rund 0,45. Dieses Ergebnis spiegelt die relativ homogene Struktur der ER-Netze wider, bei denen zufällige Knotenausfälle die globale Konnektivität erst spät beeinträchtigen. Gleichzeitig zeigt sich, dass auch skalenfreie Netze bei ungerichteten Störungen keine besondere strukturelle Schwäche aufweisen.

Gezielte Angriffe nach Knotengrad Bei gradbasierten Angriffen tritt ein deutlich anderes Bild auf. Das Barabási–Albert-Netzwerk bricht frühzeitig zusammen und erreicht mit einer AUC von etwa 0,20 den mit Abstand niedrigsten Wert. Erdős–Rényi- und Watts–Strogatz-Netzwerke bleiben dagegen deutlich stabiler ($AUC \approx 0,41$). Dieses Ergebnis bestätigt quantitativ die in der Literatur bekannte hohe Verwundbarkeit skalenfreier Netzwerke gegenüber gezielten Angriffen auf hochgradige Knoten.

Gezielte Angriffe nach Betweenness Auch bei Angriffen auf Knoten mit hoher Betweenness-Zentralität zeigt sich eine starke Differenz zwischen den Modellen. Das Barabási–Albert-Netzwerk erreicht erneut nur eine sehr geringe AUC von etwa 0,21, während Erdős–Rényi mit $AUC \approx 0,41$ und Watts–Strogatz mit etwa 0,38 deutlich robuster bleiben. Im Vergleich zum gradbasierten Angriff fällt der Unterschied zwischen ER und WS hier stärker ins Gewicht, was auf die Bedeutung vermittelnder Knotenpositionen in Small-World-Strukturen hindeutet.

Gesamtbewertung Die AUC-Auswertung bestätigt die zuvor beobachteten Kurvenverläufe in kompakter Form. Skalenfreie Netzwerke sind gegenüber zufälligen Ausfällen vergleichsweise robust, reagieren jedoch extrem empfindlich auf gezielte Angriffe. Erdős–Rényi- und Watts–Strogatz-Netze zeigen dagegen ein insgesamt ausgeglicheneres Robustheitsverhalten über alle Szenarien hinweg. Die geringe Streuung der AUC-Werte über die Wiederholungen hinweg unterstreicht zudem die Stabilität der beobachteten Effekte.